

PLN com DeepLearning – Ufma 2026.1 – Prova 1

1 - Para cada item, **escreva a expressão regular** que valida exatamente o formato descrito, respeitando as restrições indicadas. Use âncoras ^ e \$ em todos os itens

a) Dado o log de um servidor web:

```
192.168.1.1 - - [10/Mar/2024:14:32:10 -0300] "GET /index.html HTTP/1.1" 200 1234
10.0.0.5 - - [10/Mar/2024:14:33:45 -0300] "POST /api/login HTTP/1.1" 401 52
172.16.0.1 - - [11/Mar/2024:09:15:22 -0300] "GET /images/logo.png HTTP/1.1" 304 0
192.168.1.1 - - [11/Mar/2024:10:01:03 -0300] "GET /admin.php HTTP/1.1" 403 198
```

Escreva uma única ER para extrair: IP, data/hora, método HTTP, path, código de status e tamanho da resposta.

b) Placa de veículo

Formato antigo ABC-1234 ou Mercosul ABC1D23

ABC-1234 / BRA1A23

abc-1234 / ABCD-123

c) Senha forte

Mínimo de 10 caracteres, contendo pelo menos: uma letra maiúscula, uma minúscula, um dígito e um caractere especial entre !@#\$%^&*()

2 - Calcule a distância de Levenshtein entre as strings "CASAMENTO" e "CASARAO"

a) Construa a matriz completa (10x8).

c) Faça o backtracking para encontrar a sequência de operações ótima.

Indique: (i) operação, (ii) posição, (iii) custo acumulado.

3 – Considere o Corpus abaixo (stopwords removidas):

```
D1: processamento linguagem natural linguagem computacao
D2: linguagem natural processamento texto mineracao texto
D3: computacao processamento linguagem estatistica linguagem
D4: mineracao texto dados computacao estatistica
```

a) Construa a matriz de coocorrência termo-termo (simétrica, 8x8) com janela de contexto = 2. Use contagem bruta (frequência de coocorrência dentro da janela).

b) Qual par de termos tem a maior associação?

c) Calcule TF bruto (frequência do termo no documento) para todos os termos em todos os documentos.

d) Calcule IDF (log10) para cada termo do vocabulário. Use $IDF(t) = \log_{10}(N / df(t))$, onde $N=4$ e $df(t)$ é o número de documentos contendo t .

e) Calcule TF-IDF para cada termo-documento, construindo a matriz TF-IDF (4 documentos x 8 termos).

f) Calcule a similaridade do cosseno entre D1 e D2 usando os vetores TF-IDF.

5 - Usando o mesmo corpus da questão 3, calcule BM25 para a query $Q = \text{"linguagem computacao"}$. Parâmetros: $k_1 = 1.2$, $b = 0.75$.

a) Calcule o score BM25 para cada documento. Mostre cada componente do cálculo.

b) Ranqueie os documentos por relevância (maior score primeiro).

06/05/26

l.	D1	D2	D3	D4	D1	D2	D3	D4
processamento	$1 \cdot \log_{10}(\frac{4}{3})$	$1 \cdot \log_{10}(\frac{4}{3})$			$\log_{10}(\frac{4}{3})$	$\log_{10}(\frac{4}{3})$	$\log_{10}(\frac{4}{3})$	0
linguagem	$2 \cdot \log_{10}(\frac{4}{3})$	$1 \cdot \log_{10}(\frac{4}{3})$			$2 \cdot \log_{10}(\frac{4}{3})$	$\log_{10}(\frac{4}{3})$	$2 \cdot \log_{10}(\frac{4}{3})$	0
natural	$1 \cdot \log_{10}(2)$	$1 \cdot \log_{10}(2)$			$\log_{10}(2)$	$\log_{10}(2)$	0	0
computação	$1 \cdot \log_{10}(\frac{4}{3})$	0			$\log_{10}(\frac{4}{3})$	0	$\log_{10}(\frac{4}{3})$	$\log_{10}(\frac{4}{3})$
telas	0	$1 \cdot \log_{10}(2)$			0	$\log_{10}(2)$	0	$\log_{10}(2)$
minutos	0	$1 \cdot \log_{10}(2)$			0	$\log_{10}(2)$	0	$\log_{10}(2)$
estatística	0	0			0	0	$\log_{10}(2)$	$\log_{10}(2)$
dados	0	0			0	0	0	$\log_{10}(4)$

Ai	processamento	linguagem	natural	computação	telas	minutos	estatística	dados
processamento	0	2	0	1	1	0	0	0
linguagem	2 2	0	3	1	0	0	2	0
natural	1	3	0	0	0	0	0	0
computação	1	1	0	0	0	0	1	1
telas	1 1	0	0	0	0	3 3	0	1
minutos	0 0	0	0	0	3 3	0	0	0
estatística	0	2 2	0	1	0	0	0	0
dados	0	0	0	1	1	0	0	0

b. Os pontos de menor correlação são: linguagem natural, e minutos telas.